INFORMATIONSBEDARF

Art, Menge und Qualität der Informationen, die eine Person für ihre Aufgabe in einer bestimmten Zeit braucht.

Begriff	Bedeutung
objektiver Bedarf	was die Aufgabe wirklich erfordert
subjektiver Bedarf	was die Person für nötig hält
Nachfrage	was sie tatsächlich anfragt
Angebot	was verfügbar ist

Ziel: möglichst große Schnittmenge. **Pull** = Nutzer holt (Abfrage). **Push** = System liefert von sich aus (Montagsbericht, Warnung).

BI UND DATA WAREHOUSE

BI: Konzepte, Prozesse, Werkzeuge, um Unternehmens- und Wettbewerbsdaten in Wissen für Entscheidungen umzuwandeln.

Aufbau: operative Systeme (OLTP) + externe Daten → **ETL** → **Data Warehouse** → **Data Marts** → BI-Frontend (Berichte, Analysen)

- **DWH:** aktuelle **und historische** Daten, verdichtet.
- **Data Mart:** Teilbereich des DWH, v. a. für Geschwindigkeit (z. B. Vertrieb).
- **ETL:** extrahieren, transformieren, laden.
- DWH-Anforderungen: **Themenorientierung**, **Vereinheitlichung**, **Beständigkeit** (nicht mehr geändert), **Zeitraumbezug**.

Transformation (das T):

Schritt	Beispiel
Bereinigung	fehlende/falsche Werte, Platzhalter „01.01.1900“
Harmonisierung	„Spanien“, „ES“, „España“ → eine Schreibweise
Verdichtung	Umsatz je Reiseziel und Monat
Anreicherung	Kennzahl berechnen: Deckungsbeitrag je Reise

VIER ANALYSESTUFEN

Stufe	Frage	Beispiel
1 deskriptiv	Was ist passiert?	Umsatz je Reiseziel letztes Quartal
2 diagnostisch	Warum?	Warum sanken Spanien-Buchungen?
3 prädiktiv	Was wird passieren?	Buchungen Griechenland Sommer 2027
4 präskriptiv	Was sollen wir tun?	Welches Angebot an welchen Kunden?

BI: vor allem Stufe 1–2, Data Science: 3–4 (vereinfacht).

DATA SCIENCE, KI, ML

- **Data Science:** interdisziplinär (Informatik, Statistik, Fachwissen), gewinnt mit wissenschaftlichem Vorgehen Informationen aus großen Datenbeständen für Entscheidungen.
- KI ⊃ Machine Learning ⊃ Deep Learning ⊃ Generative KI.
- **Expertensystem:** feste Regeln von Menschen. **ML:** lernt Regeln aus Daten.
- ML ist ein Werkzeug der Data Science, nicht umgekehrt.

CRISP-DM (mit Rücksprüngen, kein Wasserfall):

1. Business Understanding · 2. Data Understanding · 3. Data Preparation · 4. Modelling · 5. Evaluation · 6. Deployment

METHODE WÄHLEN

Zeile = Beobachtung, Spalte = Merkmal (Feature), **Zielspalte** (Target) = was vorhergesagt wird.

1. Zielspalte mit bekannten Antworten? Nein → **unüberwacht: Clustering** (Gruppen finden).
2. Ja → **überwacht**. Zielspalte ist Zahl → **Regression**; Kategorie → **Klassifikation**.
3. Gegenprobe: Reicht Summieren/Aufschlüsseln vorhandener Zahlen? → **BI-Bericht**, kein Modell.

Frage	Methode
Umsatz je Reiseziel letztes Quartal	BI-Bericht
Buchungen Kreta Juli 2027	Regression
Wird die Buchung storniert?	Klassifikation
Kundengruppen mit ähnlichem Verhalten	Clustering
Mail: Beschwerde, Umbuchung oder Info?	Klassifikation
Warum war die Stornoquote im Mai hoch?	BI-Bericht (Drill-down)
Kreditkartenbetrug?	Klassifikation oder Ausreißererkennung

Clustering: ähnlich innerhalb, verschieden zwischen Gruppen; Bedeutung gibt der Mensch. **Train/Test:** z. B. 80 % lernen, 20 % testen; Modell sieht Testantworten nicht; erkennt Overfitting (Auswendiglernen).

TYPISCHE FEHLER

- Nachfrage mit objektivem Bedarf verwechseln.
- DWH speichere nur aktuelle Einzelbuchungen: falsch, auch historische, verdichtet.
- „Warum“-Fragen als prädiktiv einordnen: Sie sind diagnostisch.
- Harmonisierung und Bereinigung vertauschen.
- Methode nach Speicherform wählen: „storniert ja/nein“ als 1/0 bleibt Klassifikation.
- Anzahl (Buchungen im Juli) als Klassifikation einordnen: Regression.
- Für reine Auswertungen ein Modell vorschlagen statt eines BI-Berichts.
- Data Science als Werkzeug des ML bezeichnen.