Laut Kapitel nicht klausurrelevant: Praxiswissen zur Einordnung.

TRAIN-TEST-SPLIT

- **Trainingsdaten** (z. B. 80 %): Modell lernt; ein Teil kann als **Validierung** zum Abstimmen der Einstellungen dienen.
- **Testdaten** (z. B. 20 %): fertiges Modell einmal abschließend bewerten; Modell sieht die Antworten nicht.
- **Overfitting:** Trainingsdaten samt Rauschen auswendig gelernt → im Training sehr gut, auf neuen Daten deutlich schlechter.
- **Underfitting:** Modell zu einfach, schon im Training schlecht.

ENTSCHEIDUNGSBAUM UND HYPERPARAMETER

Entscheidungsbaum: teilt Daten Schritt für Schritt an Fragen („Lernstunden < 5?"); Blätter enthalten die Vorhersage; leicht zu erklären.

	Modellparameter	Hyperparameter
wann	nach dem Training, aus Daten gelernt	vor dem Training festgelegt
was	Regeln, nach denen vorhergesagt wird	steuern, wie gelernt wird
Beispiel	konkrete Fragen im Baum	maximale Tiefe, k bei k-Means

Grid Search: alle Kombinationen eines Rasters ausprobieren (Tiefe 1–4 × Merkmale 1–4 = 16), jede auf Validierungsdaten bewerten, beste nehmen.

MODELLE BEWERTEN

Konfusionsmatrix (200 Testbuchungen, 10 wirklich storniert):

	vorhergesagt storniert	vorhergesagt nicht storniert
wirklich storniert	TP = 8	FN = 2
wirklich nicht storniert	FP = 12	TN = 178

1. **Accuracy** = (TP + TN) / alle = 186 / 200 = **93 %**
2. **Precision** = TP / (TP + FP) = 8 / 20 = **40 %** (Wie viele Alarme stimmen?)
3. **Recall** = TP / (TP + FN) = 8 / 10 = **80 %** (Wie viele echte Fälle gefunden?)

- True/False = Vorhersage richtig/falsch; Positive/Negative = vorhergesagt „storniert"/„nicht storniert".
- Bei seltenen Ereignissen ist Accuracy irreführend.

- **Data Leakage:** Merkmal enthält Information, die bei der Vorhersage noch nicht bekannt wäre (Erstattungsbetrag nach Storno) → Spalte entfernen.

K-MEANS-CLUSTERING

Teilt Daten ohne Zielspalte in k Gruppen:

1. k festlegen (Hyperparameter), k Startzentren setzen.
2. Jeden Punkt dem nächsten Zentrum zuordnen.
3. Jedes Zentrum auf den Mittelwert seiner Punkte verschieben.
4. 2 und 3 wiederholen, bis sich die Zuordnung nicht mehr ändert.

- Ergebnis: Zuordnung der Punkte und Zentren (nicht k).
- Merkmale vorher **skalieren**, sonst dominiert z. B. Umsatz in Euro die Anzahl Buchungen.
- Segmentierung: Kunden ohne Buchung entfernen (eigenes nutzloses Cluster, Division durch null bei „Umsatz pro Buchung"); Kennungen (Kundennummer, Name) und Postleitzahl als Zahl nicht nutzen.

GENAI-STUFEN UND DATAIKU

Anpassungsstufen: fertige Sprachmodelle → Prompt Engineering → eigenes Wissen (RAG) → Fine-Tuning. So einfach wie möglich anfangen.

Dataiku-Begriff	Bedeutung
Flow	visuelle Pipeline aus Datasets, Recipes, Modellen
Dataset	Zeiger auf Datenquelle, keine Kopie
Recipe	Aktion auf Datasets: Stack, Join, Prepare, Split
Lab / AutoML	trainiert und vergleicht mehrere Modelle
Deploy, Score	bestes Modell übernehmen, auf neue Daten anwenden

Titanic-Aufgabe: Survived = 0/1 → binäre Klassifikation.

TYPISCHE FEHLER

- Hohe Genauigkeit auf Trainingsdaten als Beleg für gute Vorhersagen nehmen.
- Maximale Baumtiefe als Modellparameter bezeichnen: Hyperparameter.
- 95 % Accuracy bei 5 % positiven Fällen für gut halten.
- Precision und Recall vertauschen.
- k für das Ergebnis von k-Means halten.
- Merkmale vor k-Means nicht skalieren.
- Survived = 0/1 als Regression einordnen.
- Kundensegmentierung als Klassifikation bezeichnen: Clustering.